

Sistema Inteligente de Monitoreo Ambiental y Alertas Tempranas para Santander

Reporte Técnico

Jose M. López Maria C. Caicedo Juan D. Valencia Samuel F. Moncayo
Kevin Pérez

28 de mayo de 2026

Resumen

Este reporte describe el diseño, la implementación y los resultados de un sistema de alertas tempranas para desastres naturales y antrópicos en el departamento de Santander, Colombia. El sistema combina tres capas de modelado: una regresión logística como clasificador base, un ajuste bayesiano que incorpora rareza climática regional, y una cadena de Markov sobre tres estados de riesgo. El trabajo se hizo con datos públicos de IDEAM y datos.gov.co, sobre 96 municipios y un panel temporal de 51 meses. Reportamos lo que el sistema logra, lo que no logra, y por qué creemos que esas limitaciones se explican más por los datos disponibles que por las decisiones de modelado.

Índice

1. Introducción	3
2. Estado del arte	3
2.0.1. Extracción de Características y Reducción de Dimensionalidad	3
2.0.2. Modelos Espacio-Temporales	4
2.0.3. Modelos de Lenguaje y Optimización Emergente	4
2.0.4. Modelos Multimodales en Redes de Ensamble	4
3. Diseño y metodología	4
3.1. Datos y fuentes	4
3.2. Cobertura espacial: estrategia multi-nivel	5
3.3. Construcción de <i>features</i>	6
3.4. El problema del desbalanceo y la decisión de usar SMOTE	6
3.5. Capa 1: clasificador base	7
3.6. Capa 2: ajuste bayesiano	7
3.7. Capa 3: cadena de Markov	7
3.8. Score final y niveles de alerta	8
3.9. Validación	8
4. Resultados	8
4.1. Comparación de modelos en la capa de clasificación	8
4.2. Importancia de <i>features</i>	9
4.3. Capa bayesiana: comportamiento detallado	9
4.4. Cadena de Markov sobre estados de riesgo	10
4.5. Dashboard de alertas para 2024-03	10

5. Discusión ética	11
6. Conclusiones	12

1. Introducción

Santander es un departamento con condiciones geográficas y climáticas muy variadas: tiene zonas de páramo, valles, bosques y áreas urbanas grandes, y por eso convive con varios tipos de desastres al mismo tiempo. En el periodo que estudiamos (2020–2024) se reportaron cerca de 970 eventos: incendios forestales, inundaciones, crecientes súbitas, deslizamientos, tormentas eléctricas y otros. La pregunta detrás de este proyecto es bastante directa: **¿se puede usar información climática pública para anticipar, al menos un mes antes, en qué municipios es más probable que ocurra un desastre?**

La pregunta es directa pero responderla es difícil. Para empezar, los datos son pequeños: 96 municipios por 51 meses dan 1.344 observaciones, y solo el 18,6 % de esas filas tiene al menos un desastre. Además, no todos los municipios tienen una estación climática del IDEAM: 25 de 96 no tienen estación propia, así que sus mediciones se aproximan desde estaciones vecinas o del promedio departamental. A eso se suma que el clima en Santander cambia mucho entre una vereda y la siguiente, así que la señal que llega al modelo no es del todo limpia.

Frente a esto, decidimos no apostar por un solo modelo grande y complejo, sino por una arquitectura de tres capas donde cada una aporta una cosa distinta y compensa una debilidad de la anterior. Un clasificador aprende los patrones históricos a partir de las variables climáticas. Sobre la probabilidad que entrega ese clasificador aplicamos un ajuste bayesiano que incorpora dos cosas que el modelo por sí solo no sabe: qué tan raro es el municipio dentro de su grupo climático y qué tan anómala fue la precipitación del mes. Por último, una cadena de Markov sobre estados de riesgo Bajo/Medio/Alto añade la dimensión temporal: el riesgo de hoy no es solo el de hoy, también es hacia dónde va. El resultado final es un *score* continuo entre 0 y 1 que se traduce en cuatro niveles de alerta (Roja, Naranja, Amarilla y Sin alerta).

El objetivo de este reporte no es solo presentar los números. También queremos dejar claras las decisiones de diseño y por qué las tomamos así, porque creemos que en un problema como este la calidad del razonamiento detrás del modelo importa tanto como las métricas finales.

2. Estado del arte

El diseño e implementación de sistemas inteligentes de monitoreo ambiental y alertas tempranas ha evolucionado significativamente durante la última década. Tradicionalmente, la gestión de desastres naturales dependía de enfoques reactivos, análisis estadísticos estáticos y ajustes manuales que limitaban la capacidad de anticipar eventos con suficiente tiempo [1]. En los últimos años, el aumento de los efectos del cambio climático y el crecimiento urbano han incrementado la complejidad de los riesgos ambientales y su comportamiento en el espacio y el tiempo [2].

Frente a este panorama, los enfoques actuales integran técnicas de Inteligencia Artificial, aprendizaje profundo y arquitecturas de procesamiento por capas. La investigación reciente se ha centrado en problemas como la extracción automática de características en datos no lineales, el manejo de conjuntos de datos desbalanceados, el procesamiento de información heterogénea en tiempo real y la incorporación de mecanismos de interpretabilidad que permitan entender las decisiones de los modelos.

2.0.1. Extracción de Características y Reducción de Dimensionalidad

La predicción de fenómenos climáticos extremos a mediano y largo plazo suele verse afectada por la complejidad y el ruido presente en los datos. Por este motivo, algunos trabajos recientes combinan técnicas de procesamiento de señales y métodos de optimización para mejorar las entradas de los modelos predictivos. Entre ellos, se ha utilizado la Transformada de Dispersión Wavelet para extraer características relevantes y algoritmos de Optimización por Enjambre de Partículas para seleccionar variables [1]. Estos enfoques, integrados con arquitecturas convolucio-

nales como DenseNet-169, han mostrado resultados favorables en la predicción multiestacional de eventos severos como ciclones y ríos atmosféricos [1].

2.0.2. Modelos Espacio-Temporales

Los desastres con comportamiento rápido o con fuertes dependencias espaciales, como inundaciones y terremotos, requieren sistemas capaces de integrar información espacial y temporal de forma conjunta. En este contexto, el Internet de las Cosas y las soluciones AIOps se han utilizado para automatizar la monitorización ambiental mediante redes de sensores distribuidos [2]. Estas arquitecturas conectan dispositivos en el borde con servicios en la nube para procesar datos ambientales en tiempo real [2]. Además, modelos híbridos como CNN-LSTM permiten capturar patrones espacio-temporales, mientras que las Redes Neuronales de Grafos (GNN) se utilizan para modelar la propagación de eventos sobre regiones geográficas específicas.[2].

2.0.3. Modelos de Lenguaje y Optimización Emergente

Una de las líneas recientes en la predicción de riesgos específicos, como los incendios forestales, es la incorporación de información geográfica e histórica mediante arquitecturas de Generación Aumentada por Recuperación. El modelo FlameRAG-SHO combina datos satelitales, como temperatura superficial e índices de vegetación, con antecedentes históricos y restricciones espaciales para mejorar el contexto de las predicciones [3]. Además, utiliza el algoritmo de optimización SHO para el ajuste de hiperparámetros, obteniendo resultados favorables en la estimación de riesgo en tiempo real [3].

2.0.4. Modelos Multimodales en Redes de Ensamble

Cuando el objetivo del sistema incluye estimar la severidad del impacto y las pérdidas asociadas a un desastre, los modelos tradicionales pueden resultar limitados frente a la diversidad de los datos de entrada [4]. En este contexto, arquitecturas multimodales como FusionNet+ organizan el problema en varios módulos: uno orientado al análisis espaciotemporal de variables climáticas, otro para integrar información socioeconómica y de infraestructura, y una capa de fusión encargada de combinar las salidas del sistema [4]. Este tipo de enfoque permite procesar simultáneamente datos climáticos, registros históricos y fuentes de información en tiempo real [4]. Además, estos sistemas incorporan técnicas de Inteligencia Artificial Explicable, como SHAP y LIME, para facilitar la interpretación de las predicciones y el aporte de cada conjunto de datos en la alerta generada [4].

El análisis del estado del arte muestra que los sistemas de alerta temprana más eficaces tienden a utilizar arquitecturas híbridas y modulares, en lugar de modelos predictivos monolíticos [1]. La literatura evidencia que la combinación de clasificadores base con técnicas de optimización metaheurística, modelos espaciotemporales y mecanismos de enriquecimiento contextual mejora la sensibilidad, la precisión y la capacidad de anticipación frente a eventos climáticos extremos [1].

Asimismo, los estudios coinciden en que la efectividad de un sistema de alerta temprana no depende únicamente del diseño de los algoritmos, sino también de la calidad, granularidad y diversidad de los datos, así como de la explicabilidad de los resultados [2], [4]. Estos hallazgos sustentan el diseño propuesto en este documento para generar alertas en el departamento de Santander.

3. Diseño y metodología

3.1. Datos y fuentes

Trabajamos con cuatro fuentes públicas, todas del portal datos.gov.co e IDEAM:

- **Desastres naturales y antrópicos:** aproximadamente 970 registros para Santander, con fecha, tipo de evento, municipio, severidad y afectados.
- **Temperatura ambiente del aire** (IDEAM): rango 2020-01-01 a 2024-03-29.
- **Precipitación** (IDEAM): rango 2020-01-01 a 2024-03-16.
- **Humedad del aire** (IDEAM): mismo rango.

Cargamos primero los desastres porque eran el conjunto más pequeño y nos permitían fijar el alcance geográfico y temporal. Después filtramos los datos climáticos solo para Santander y dentro del rango de los desastres. El paso final fue cruzar las dos fuentes a nivel de municipio y mes.

La Tabla 1 muestra cómo está repartido el conjunto de desastres por tipo. La distribución es muy desigual: los incendios forestales solos representan cerca de un tercio de todos los reportes, seguidos por inundaciones, crecientes súbitas y deslizamientos. Hay también una estacionalidad fuerte: febrero concentra el pico de eventos (153), enero el segundo (116), y diciembre es el mes con menos (27). Esto sugiere que un buen modelo necesita variables que capten tanto el patrón anual como las rachas dentro del año.

Tabla 1: Tipos de desastre más frecuentes en Santander (2020–2024).

Tipo de evento	Cantidad de reportes
Incendio forestal	~310
Inundaciones	~115
Creciente súbita	~105
Deslizamientos	~65
Tormentas eléctricas	~60
Movimiento en masa	~55
Cierre de vía	~50
Granizada	~40

3.2. Cobertura espacial: estrategia multi-nivel

Uno de los problemas más serios fue que muchos municipios donde ocurren desastres no tienen estación del IDEAM. Si descartamos esos municipios, perdemos buena parte del dataset; si forzamos un valor cualquiera, metemos ruido. Por eso usamos una estrategia de tres niveles, donde cada evento se cruza con el mejor nivel disponible, priorizando precisión espacial (Tabla 2).

Tabla 2: Estrategia multi-nivel para asignar datos climáticos a cada municipio.

Nivel	Estrategia	Precisión espacial	Cobertura
1	Municipio exacto + promedio mensual	Alta	~15 %
2	Estación más cercana por coordenadas + promedio	Media	~60 %
3	Promedio departamental mensual	Baja (regional)	100 %

Es importante reconocer que el Nivel 3 es básicamente una imputación regional: usar el promedio del departamento equivale a decir que no sabemos qué pasó en el municipio. Mantenerlo nos garantiza cobertura completa, pero nos costó precisión en aproximadamente un cuarto de los municipios.

3.3. Construcción de *features*

Las variables crudas (temperatura, precipitación y humedad medias del mes) no alcanzan para que un modelo aprenda algo útil. El clima es un fenómeno con memoria y con ritmo, así que añadimos variables que captaran eso. En total, el panel terminó con 43 *features*.

- **Estadísticas básicas por mes:** media, desviación estándar, mínimo y máximo de temperatura, precipitación y humedad. Cuatro estadísticos $\times$ tres variables: doce *features*.
- **Lags de 1, 2 y 3 meses:** un incendio que ocurre en febrero suele venir gestándose desde el clima de diciembre y enero. Los *lags* dan al modelo acceso a esa historia reciente.
- **Ventanas móviles de 3 y 6 meses (*rolling*):** permiten distinguir una racha climática sostenida de un pico aislado. Un verano largo no es lo mismo que un día caluroso.
- **Z-scores:** cada variable se compara con su comportamiento histórico en ese mismo municipio. Esto convierte una temperatura “alta” en una temperatura “alta para ese sitio”.
- **Codificación cíclica del mes (*sin/cos*):** si codificamos el mes como un número del 1 al 12, diciembre (12) y enero (1) quedan separados como los puntos más lejanos del año, lo cual es falso. Usando $\sin(2\pi \cdot \text{mes}/12)$ y $\cos(2\pi \cdot \text{mes}/12)$, diciembre y enero quedan vecinos, como deben estar.
- **Lags de desastres (*desastre_lag1, desastre_lag2*):** la ocurrencia de un desastre el mes anterior es, como veremos, la variable más predictiva del conjunto. Los desastres no ocurren al azar; ocurren en rachas estacionales.
- **Features de *clustering* regional:** agrupamos los 96 municipios por perfil climático (temperatura, precipitación y humedad medias) usando K-Means. La búsqueda del K óptimo se hizo con el coeficiente de silueta, que mide qué tan bien queda cada punto dentro de su grupo. El máximo se dio en $K = 5$ con silueta = 0,810. De ese ejercicio se derivaron tres variables: el *cluster* al que pertenece el municipio, su distancia al centroide (*dist_centroide*) y un *z-score* de rareza (*rareza_z*) que mide qué tan atípico es respecto a su grupo. El municipio más atípico fue Sabana de Torres, con *rareza_z* = 4,433.

Probamos también añadir regresiones para predecir temperatura y precipitación del mes siguiente, pero los resultados fueron pobres ($R^2 = -2,303$ para temperatura y $R^2 = 0,000$ para precipitación) y descartamos esos *features*: si un modelo tiene R^2 negativo, predice peor que la media global, así que conservarlo solo agrega ruido.

3.4. El problema del desbalanceo y la decisión de usar SMOTE

El 81 % de los meses-municipio no tuvo desastre y el 18,6 % sí. Un modelo perezoso que siempre prediga “no desastre” acertaría el 81 % sin haber aprendido nada. Por eso el *accuracy* no es una métrica útil aquí, y por eso medimos con F1 y *Average Precision*.

Para reducir el desbalanceo durante el entrenamiento usamos SMOTE (*Synthetic Minority Over-sampling Technique*), que genera ejemplos sintéticos de la clase minoritaria interpolando entre vecinos reales. Después de aplicarlo, el conjunto de entrenamiento quedó balanceado en 696 ejemplos por clase (1.392 en total).

Una decisión que importa en este punto es *cuándo* aplicar SMOTE en el *pipeline*:

- Si escalamos primero (*StandardScaler*) y luego aplicamos SMOTE, todas las variables comparten escala antes de la interpolación, así que los vecinos que SMOTE encuentra son “ceranos” de verdad. Este es el orden correcto y es el que usamos.

- Si lo hiciéramos al revés, la temperatura (que tiene rangos de decenas) dominaría sobre la humedad y la precipitación, y los ejemplos sintéticos serían artificiales.

También evitamos combinar SMOTE con `class_weight='balanced'` en el clasificador, porque eso compensa dos veces el mismo problema, descalibra las probabilidades y termina haciendo que el modelo prediga “desastre” para casi todo. (Como se verá en los resultados, este problema apareció igual, pero por otra ruta.)

3.5. Capa 1: clasificador base

Comparamos tres modelos: *Random Forest*, *Gradient Boosting* y *Regresión Logística*. La Regresión Logística terminó siendo nuestra elección, no porque fuera la más poderosa, sino porque encajaba mejor con las restricciones del problema:

- Sus coeficientes son interpretables: se puede decir, para cada variable, cuánto sube o baja la probabilidad de desastre.
- Sus probabilidades están razonablemente calibradas, lo cual es importante porque la siguiente capa (la bayesiana) opera sobre esas probabilidades.
- Trabaja bien con SMOTE en el espacio escalado.
- No requiere tantos datos como un *Gradient Boosting* para entrenarse de manera estable.

El *Random Forest* se descartó principalmente porque sus probabilidades suelen estar mal calibradas (su *score* no es realmente una probabilidad sino un voto). El *Gradient Boosting* se descartó porque, con apenas ~ 845 filas de entrenamiento, tiende a sobreajustarse y a producir probabilidades poco confiables.

3.6. Capa 2: ajuste bayesiano

El clasificador aprende correlaciones históricas, pero no sabe nada de contexto. No sabe, por ejemplo, que Sabana de Torres es un municipio raro dentro de su cluster, ni que la precipitación de este mes está cuatro desviaciones por encima de lo habitual. La capa bayesiana inyecta esa información usando *razones de verosimilitud* (*likelihood ratios*).

Sea p_{clf} la probabilidad que entrega la regresión logística y π el *prior* de desastre (en el entrenamiento $\pi = 0,1763$). Definimos las *odds* del clasificador como $\text{odds}_{\text{clf}} = p_{\text{clf}} / (1 - p_{\text{clf}})$. El *posterior* se obtiene aplicando dos factores multiplicativos:

$$\text{odds}_{\text{post}} = \text{odds}_{\text{clf}} \times (1 + 0,15 \cdot \text{máx}(0, z_{\text{rareza}})) \times (1 + 0,10 \cdot \text{máx}(0, z_{\text{prec}})) \quad (1)$$

Donde z_{rareza} es el *z-score* de rareza del municipio respecto a su *cluster* y z_{prec} es el *z-score* de la precipitación del mes. Los factores 0,15 y 0,10 son ponderaciones que escogimos para que el ajuste sea notorio pero no domine al clasificador. Solo se aplica el ajuste cuando el *z-score* es positivo (rareza o anomalía hacia arriba); valores normales no modifican las *odds*.

¿Por qué hacer este ajuste con Bayes y no con otro clasificador? Porque Bayes es interpretable (sabemos exactamente cómo el modelo cambia su opinión), permite incorporar conocimiento de dominio, y no requiere reentrenar nada cuando se ajustan los pesos.

3.7. Capa 3: cadena de Markov

La probabilidad de un mes en aislado no captura la dinámica del riesgo: un municipio que viene en estado *Alto* tres meses seguidos no es lo mismo que uno que entra a *Alto* por primera vez. Para añadir esta dimensión temporal modelamos el riesgo como una cadena de Markov de tres estados: Bajo, Medio y Alto.

Los umbrales que separan los estados se eligieron con los percentiles 33 y 66 de la distribución de probabilidades posteriores: $\text{THR}_{\text{Bajo}} = 0,323$ y $\text{THR}_{\text{Alto}} = 0,512$. La matriz de transición P se estimó contando las transiciones observadas entre meses consecutivos en el panel completo.

Elegimos Markov en lugar de modelos secuenciales más sofisticados (LSTM, ARIMA) porque solo tenemos ~ 51 puntos de tiempo por municipio. Un LSTM necesita muchos más datos para entrenarse sin sobreajustar. Markov tiene la ventaja adicional de ser interpretable: la matriz de transición se puede leer directamente.

3.8. Score final y niveles de alerta

El *score* de alerta combina la probabilidad bayesiana del mes y la probabilidad de transicionar a estado *Alto* en el mes siguiente:

$$\text{score} = 0,70 \cdot p_{\text{bayes}} + 0,30 \cdot P(\text{Alto}_{t+1}) \quad (2)$$

La ponderación 70/30 le da más peso al estado presente que a la proyección futura, porque la proyección es más incierta. El *score* se traduce a niveles según la Tabla 3.

Tabla 3: Niveles de alerta según el score combinado.

Nivel	Score
Alerta Roja	$\geq 0,50$
Alerta Naranja	$\geq 0,25$
Alerta Amarilla	$\geq 0,10$
Sin alerta	$< 0,10$

3.9. Validación

Para evaluar el sistema usamos tres reglas que evitan que las métricas se “inflen” artificialmente.

Primero, split temporal. No usamos validación cruzada aleatoria porque eso permitiría que el modelo viera el futuro mientras se entrena. Cortamos el panel por una fecha (*cutoff*); todo lo anterior fue entrenamiento (1.056 filas) y todo lo posterior fue prueba (288 filas: 207 sin desastre y 81 con desastre).

Segundo, validación separada para el umbral. El umbral τ^* que decide cuándo el sistema dice “desastre” se optimiza sobre el 20 % final del conjunto de entrenamiento, no sobre el test. Si lo optimizáramos sobre el test, las métricas reportadas serían las del mejor caso posible para esos datos, no las del comportamiento real.

Tercero, métricas asimétricas. Reportamos F1, AP (*Average Precision*) y AUC, no *accuracy*. En un sistema de alertas un falso negativo (no avisar de un desastre que ocurre) cuesta mucho más que una falsa alarma, así que la métrica tiene que reflejar esa asimetría.

4. Resultados

4.1. Comparación de modelos en la capa de clasificación

La Tabla 4 resume las métricas sobre el conjunto de prueba (288 registros).

Tres observaciones:

1. La regresión logística supera al Random Forest en F1 y AP. El Random Forest la supera en AUC, pero la diferencia es pequeña y el AUC en este caso es un indicador menos relevante que F1 (porque la base es desbalanceada).

Tabla 4: Comparación de modelos sobre el conjunto de prueba.

Modelo	F1	AP	AUC-ROC	τ^*
Random Forest	0,387	0,330	0,579	0,453
Gradient Boosting	0,069	0,290	0,475	0,222
Regresión Logística	0,437	0,346	0,548	0,429
Bayesiano (RL + ajustes)	0,445	0,347	0,548	0,074

2. El Gradient Boosting falla casi por completo. Con $\tau^* = 0,222$ termina prediciendo positivo muy poco ($\text{recall} = 0,04$ en la clase “Desastre”), de ahí su F1 de 0,069. Esto confirma que el modelo no tenía datos suficientes para estabilizarse.
3. La capa bayesiana aporta una mejora pequeña sobre la regresión logística sola (F1 sube de 0,437 a 0,445). La mejora es modesta, pero el ajuste también baja el umbral óptimo de 0,429 a 0,074, lo cual quiere decir que el modelo está distribuyendo su probabilidad de manera distinta. Esto se discute en la sección siguiente.

4.2. Importancia de *features*

El *Random Forest*, aunque no fue el modelo final, dejó una salida útil: el ranking de importancia Gini de las variables. La Tabla 5 muestra el top.

Tabla 5: Top *features* más importantes (Random Forest, importancia Gini).

Feature	Importancia
desastre_lag1	0,129
dist_centroide	0,079
rareza_z	0,078
desastre_lag2	0,040
prec_media_lag2	0,036
prec_media_roll6	0,035
prec_media_roll3	0,034
hum_media_pct	0,030
temp_media	0,030

Lo más predictivo es que haya ocurrido un desastre el mes anterior (*desastre_lag1*). En segundo y tercer lugar, las dos *features* de *clustering*: *dist_centroide* y *rareza_z*. Esto confirma una intuición del diseño: la información de en qué cluster está el municipio y qué tan atípico es dentro de él aporta tanto como las variables climáticas crudas.

También es notable que la precipitación (en sus *lags* y *rolling windows*) aparece varias veces en el top, lo cual concuerda con que los tipos de desastre más frecuentes (inundación, creciente súbita, deslizamiento) están directamente relacionados con la lluvia.

4.3. Capa bayesiana: comportamiento detallado

El *prior* de desastre estimado sobre el entrenamiento fue $\pi = 0,1763$ (17,63%). Después del ajuste por rareza y anomalía, el umbral óptimo de F1 cayó a $\tau^* = 0,074$. El reporte de clasificación sobre el test mostró:

- Clase “Desastre” (81 casos reales): *precision* 0,29, *recall* 1,00, F1 = 0,45.
- Clase “Sin desastre” (207 casos reales): *precision* 1,00, *recall* 0,02, F1 = 0,05.

Esto hay que mirarlo con cuidado. El modelo bayesiano alcanza recall 1,00 en la clase positiva, lo cual suena bien (no se le escapa ningún desastre). Pero el recall casi nulo en la clase negativa significa que también está marcando como “desastre” a casi todas las observaciones donde no hay desastre. En otras palabras: dice que sí a casi todo. La precisión de la clase positiva es de apenas 29 %, lo cual es solo un poco mejor que el prior (17,6 %).

4.4. Cadena de Markov sobre estados de riesgo

La matriz de transición P estimada se muestra en la Tabla 6.

Tabla 6: Matriz de transición P de la cadena de Markov.

Desde \ Hacia	Bajo	Medio	Alto
Bajo	0,345	0,262	0,393
Medio	0,340	0,297	0,363
Alto	0,243	0,393	0,364

Y la distribución estacionaria a largo plazo es:

- $\pi_{\text{Bajo}} = 0,305$ (30,5 %)
- $\pi_{\text{Medio}} = 0,322$ (32,2 %)
- $\pi_{\text{Alto}} = 0,373$ (37,3 %)

Una lectura: desde cualquiera de los tres estados hay una probabilidad alta de saltar a *Alto* (entre 0,36 y 0,39). El sistema no estabiliza el riesgo en *Bajo*, sino que tiende a “ronquear” alrededor de *Alto*. Esto, otra vez, es una señal del desbalance del fenómeno: los desastres son frecuentes en Santander, así que la probabilidad de estar en estado de riesgo elevado es estructuralmente alta.

4.5. Dashboard de alertas para 2024-03

Aplicando el sistema completo al último mes disponible del test (marzo 2024), el resumen por nivel de alerta fue:

- **Alerta Roja: 93 municipios**
- Alerta Naranja: 3 municipios
- Alerta Amarilla: 0 municipios
- Sin alerta: 0 municipios

Los municipios con *score* más alto fueron Sabana de Torres (0,801), Mogotes (0,781) y Barichara (0,775). La Tabla 7 muestra los primeros del ranking.

Que 93 de 96 municipios queden en Alerta Roja es el resultado más incómodo del sistema. Lo discutimos a fondo en la siguiente sección, pero el origen es claro: el clasificador entrega probabilidades demasiado altas para casi todas las observaciones (efecto del SMOTE + `class_weight='balanced'`), el ajuste bayesiano las empuja todavía más arriba para los municipios atípicos, y el umbral de 0,50 termina dejando casi todo en la categoría más severa.

Tabla 7: Top de municipios con mayor score de alerta para 2024-03.

Municipio	p_{Bayes}	$p(\text{Alto}_{t+1})$	Score	Alerta
Sabana de Torres	0,988	0,364	0,801	Roja
Mogotes	0,959	0,364	0,781	Roja
Barichara	0,951	0,364	0,775	Roja
El Playón	0,951	0,364	0,775	Roja
San José de Miranda	0,951	0,364	0,775	Roja

5. Discusión ética

Un sistema que dispara alertas tiene consecuencias en el mundo real: moviliza recursos, genera comunicaciones a la población, cambia decisiones de autoridades. Por eso vale la pena pensar en sus implicaciones más allá de las métricas.

Sobre el sobre-aviso. El resultado del dashboard (93 de 96 municipios en Alerta Roja) es la principal limitación ética del sistema. Si una autoridad municipal aplicara este modelo tal cual, terminaría declarando emergencia generalizada todos los meses. Eso produce *alert fatigue*: cuando todo es urgente, nada lo es, y la gente deja de prestar atención a las alertas reales. En este sentido, un sistema que sobre-alerta puede ser tan dañino como uno que no alerta.

Sobre el costo asimétrico. En el diseño elegimos darle más peso al recall que a la precisión, partiendo de que un falso negativo (no avisar de un desastre real) cuesta vidas. Esa decisión sigue siendo defendible, pero hay que reconocer que el sistema actual la lleva al extremo: maximiza recall casi a cualquier costo, y por eso queda casi inutilizable como herramienta de discriminación. La discusión real, que escapa al alcance de este reporte, es *quién* decide la ponderación entre falsos positivos y falsos negativos. Esa decisión es política y económica, no técnica, y debería hacerse con las autoridades de gestión del riesgo, no solo en un cuaderno de Jupyter.

Sobre la desigualdad espacial de los datos. 25 de los 96 municipios no tienen estación climática propia. Esos municipios reciben datos imputados desde estaciones vecinas o desde el promedio departamental. Eso significa que las alertas en esos municipios son sistemáticamente menos precisas. Y como los municipios sin estación tienden a ser los más rurales y pequeños, terminan siendo los más vulnerables y los que peor información reciben. Esto es una forma de inequidad informacional que el sistema reproduce sin querer. Cualquier despliegue real del sistema tendría que ir acompañado de inversión en infraestructura de medición en esos municipios.

Sobre la interpretabilidad. Una de las razones por las que elegimos regresión logística + Bayes + Markov en lugar de un modelo de caja negra fue que necesitábamos poder explicar por qué el sistema dice lo que dice. Si una autoridad recibe una alerta roja para su municipio, debería poder saber qué variables la dispararon. Un modelo que solo entrega un *score* sin justificación es difícil de auditar y difícil de cuestionar. La interpretabilidad no es un lujo en este contexto: es una condición para que el sistema sea utilizable.

Sobre los límites del modelo. Reconocer los límites del sistema públicamente es parte de la honestidad técnica. Tres variables climáticas (temperatura, precipitación, humedad) y 51 meses de datos no son suficientes para predecir desastres con la precisión que requeriría una operación real. Las próximas iteraciones deberían incorporar datos satelitales (NDVI para vegetación), índices climáticos macro (ENSO: El Niño / La Niña) y validación cruzada temporal con múltiples cortes. Y, en paralelo, una discusión clara con las autoridades sobre cómo se va a usar el sistema y qué consecuencias tendría usarlo mal.

Sobre la responsabilidad. Un sistema de alertas no exime a quien decide. La probabilidad que entrega el modelo es una entrada más para una decisión humana, no la decisión en sí. Mientras eso quede claro en cualquier despliegue, el sistema puede ser útil. Si se usa como un oráculo automático, deja de serlo.

6. Conclusiones

El sistema combina tres capas que se complementan: un clasificador (regresión logística) que aprende patrones del clima, un ajuste bayesiano que incorpora rareza regional y anomalía climática, y una cadena de Markov que aporta la dimensión temporal. El mejor F1 obtenido es 0,445 (capa bayesiana), un valor modesto pero por encima del que daría un modelo aleatorio sobre una base desbalanceada.

El sistema funciona como prueba de concepto del enfoque por capas, pero todavía no funciona como sistema operativo de alertas. La razón principal no es el diseño del modelo sino la calidad y volumen de los datos: tres variables climáticas y 51 meses son una base estrecha para una pregunta tan compleja como predecir desastres.

Las limitaciones que más pesan no son fallas del modelado, sino restricciones de los datos disponibles. Sin más estaciones, sin más años y sin más variables (NDVI, ENSO, datos socioeconómicos), cualquier sistema que se construya sobre estas fuentes va a tener un techo parecido.

Referencias

- [1] S. Kumari y P. Muthulakshmi, “Improving multi-seasonal prediction, extreme weather events and climate analyses over the southwest coastal region (SCR) of Indian Ocean Dipole using advanced machine learning techniques,” *Environmental Development*, vol. 59, pág. 101 461, 2026. DOI: [10.1016/j.envdev.2026.101461](https://doi.org/10.1016/j.envdev.2026.101461).
- [2] N. Maheswaran, G. Vijayaraj, G. Logeswari, D. Prabhu, S. Bose y G. Gokulraj, “AIOPS-Enabled IoT Framework for Intelligent Early Warning and Disaster Management Systems,” en *Proceedings of the 2025 International Conference on Intelligent Computing, Information and Control Systems (ICOIICS-2025)*, IEEE, 2025. DOI: [10.1109/ICOIICS67115.2025.11390486](https://doi.org/10.1109/ICOIICS67115.2025.11390486).
- [3] V. Uma Maheswari, V. V. S. Kumar, M. P. Kumar, M. S. Prashanth, A. Patil y D. J. Bora, “FlameRAG-SHO: A Hybrid RAG and Bio-Inspired Optimisation Framework for Intelligent Wildfire Prediction Using Multi-Source Satellite Data,” en *2025 International Conference on Intelligent and Secure Engineering Solutions (CISES)*, IEEE, 2025. DOI: [10.1109/CISES66934.2025.11265305](https://doi.org/10.1109/CISES66934.2025.11265305).
- [4] 1. S. Islam, 4. M. K. K. Simul, 2. R. A. Arman, 5. A. Ullah, 3. M. Hossain y 6. S. Akter, “FusionNet+: A Multi-Modal Deep Ensemble Architecture for Predicting Natural Disaster Severity and Economic Loss,” en *IEEE 2nd International Conference on Computing, Applications and Systems (COMPAS 2025)*, IEEE, 2025. DOI: [10.1109/COMPAS67506.2025.11381628](https://doi.org/10.1109/COMPAS67506.2025.11381628).